

Desafio 01 - Análise Exploratória de Dados (EDA)

Problema de Negócio: Radar de Custo Catastrófico Hospitalar (SIH-SUS) **Métrica de Sucesso:** F1-Macro (devido ao desbalanceamento crítico do alvo) **Aluno:** André Filipe Aloise

1. Carregamento e Inspeção Inicial

Nesta etapa, carregamos a base consolidada de Dezembro de 2024 e inspecionamos os metadados para identificar o formato do arquivo bruto.

```
In [1]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

sns.set_theme(style='whitegrid')
df = pd.read_csv('../data/processed/sih_processed.csv', dtype=str)

print('Shape do Dataset:', df.shape)
print('\n--- info() ---')
df.info()
print('\n--- dtypes ---')
print(df.dtypes)
print('\n--- Head ---')
print(df.head())
```

Shape do Dataset: (1090085, 10)

```
--- info() ---
<class 'pandas.DataFrame'>
RangeIndex: 1090085 entries, 0 to 1090084
Data columns (total 10 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   MUNIC_RES                            1090085 non-null str
1   SEXO                                1090085 non-null str
2   VAL_TOT                             1090085 non-null str
3   DIAG_PRINC                          1090085 non-null str
4   GESTAO                              1090085 non-null str
5   MUNIC_MOV                           1090085 non-null str
6   IDADE                               1090085 non-null str
7   CAR_INT                             1090085 non-null str
8   INSTRU                              1090085 non-null str
9   TARGET_CUSTO_CATASTROFICO          1090085 non-null str
dtypes: str(10)
memory usage: 83.2 MB
```

```
--- dtypes ---
MUNIC_RES          str
SEXO               str
VAL_TOT            str
DIAG_PRINC         str
GESTAO             str
MUNIC_MOV          str
IDADE             str
CAR_INT            str
INSTRU             str
TARGET_CUSTO_CATASTROFICO str
dtype: object
```

```
--- Head ---
   MUNIC_RES SEXO  VAL_TOT DIAG_PRINC GESTAO MUNIC_MOV IDADE CAR_INT \
0    120013    3    801.73      K439     2    120045    49     01
1    120040    3    992.45      K808     2    120045    36     01
2    120040    3    996.34      K808     2    120045    55     01
3    120013    3    434.99      K429     2    120045    45     01
4    120040    1    637.97      K409     2    120045    58     01

   INSTRU TARGET_CUSTO_CATASTROFICO
0       0                        0
1       0                        0
2       0                        0
3       0                        0
4       0                        0
```

Análise de Tipos Errados: Identificamos que variáveis numéricas, como `IDADE` e `VAL_TOT`, foram lidas como strings devido à formatação padrão do SUS, necessitando de tipagem dinâmica dentro do Pipeline de produção.

Amostragem Estratégica para Visualizações

Como o volume excede 1 milhão de linhas, aplicamos a diretriz do edital de realizar gráficos sobre uma amostra aleatória de 50.000 registros para otimização de memória, mantendo a integridade estatística.

```
In [2]: df_sample = df.sample(50000, random_state=42).copy()
df_sample['IDADE'] = pd.to_numeric(df_sample['IDADE'], errors='coerce').fillna(0)
df_sample['TARGET_CUSTO_CATASTROFICO'] = df_sample['TARGET_CUSTO_CATASTROFICO'].
print('Amostra para EDA criada com sucesso. Shape:', df_sample.shape)
```

Amostra para EDA criada com sucesso. Shape: (50000, 10)

2. Distribuição da Variável-Alvo

Análise da frequência absoluta e percentual do desfecho de custo catastrófico.

```
In [3]: abs_target = df['TARGET_CUSTO_CATASTROFICO'].value_counts()
pct_target = df['TARGET_CUSTO_CATASTROFICO'].value_counts(normalize=True) * 100
print('Frequência Absoluta:\n', abs_target)
print('\nFrequência Percentual:\n', pct_target)

plt.figure(figsize=(6, 4))
sns.countplot(x='TARGET_CUSTO_CATASTROFICO', data=df_sample, palette='Set2')
plt.title('Distribuição da Classe Alvo (Amostra)')
plt.tight_layout()
plt.savefig('alvo_distribuicao.png')
plt.show()
```

Frequência Absoluta:

TARGET_CUSTO_CATASTROFICO

0 981076

1 109009

Name: count, dtype: int64

Frequência Percentual:

TARGET_CUSTO_CATASTROFICO

0 89.999954


1 10.000046

Name: proportion, dtype: float64

C:\Users\aaloise\AppData\Local\Temp\ipykernel_8608\1143272650.py:7: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.countplot(x='TARGET_CUSTO_CATASTROFICO', data=df_sample, palette='Set2')
```




Diagnóstico de Desbalanceamento: Conforme estabelecido pelo corte do percentil 90, o dataset apresenta 90% para custo controlado (classe 0) e 10% para custo catastrófico (classe 1), exigindo o uso de algoritmos estruturados com ajuste de pesos.

3. Distribuição das Features Numéricas

Avaliação do perfil de distribuição de idades na base.

```
In [4]: plt.figure(figsize=(8, 4))
sns.histplot(df_sample['IDADE'], kde=True, color='blue', bins=30)
plt.title('Distribuição de Idade dos Pacientes Internados')
plt.tight_layout()
plt.savefig('num_features_dist.png')
plt.show()
```




Diagnóstico Numérico: A idade apresenta um perfil bimodal nítido: picos expressivos em internações pediátricas/recém-nascidos e uma curva representativa na população idosa, espelhando os padrões de utilização hospitalar do SUS.

4. Distribuição das Features Categóricas

Mapeamento de frequência de variáveis administrativas estruturais.

```
In [5]: fig, axes = plt.subplots(1, 2, figsize=(14, 5))
sns.countplot(ax=axes[0], x='GESTAO', data=df_sample, order=df_sample['GESTAO'].
axes[0].set_title('Top Categorias de Gestão Hospitalar')
sns.countplot(ax=axes[1], x='CAR_INT', data=df_sample, order=df_sample['CAR_INT']
axes[1].set_title('Distribuição por Caráter de Internação')
plt.tight_layout()
plt.savefig('cat_features_dist.png')
plt.show()

print('Cardinalidade da coluna diagnóstica (CID):', df['DIAG_PRINC'].nunique())
```



Cardinalidade da coluna diagnóstica (CID): 7740

Identificação de Alta Cardinalidade: A coluna `DIAG_PRINC` possui altíssima cardinalidade devido aos códigos detalhados do CID-10, tornando imperativa a extração do caractere inicial do capítulo no Pipeline de treinamento.

5. Relações Entre Features e Alvo


Exploração do impacto da idade do paciente no risco de alto custo orçamentário.

```
In [6]: plt.figure(figsize=(8, 5))
sns.boxplot(x='TARGET_CUSTO_CATASTROFICO', y='IDADE', data=df_sample, palette='S
plt.title('Relação Linear: Idade do Paciente vs Custo Catastrófico')
plt.tight_layout()
plt.savefig('relacao_idade_alvo.png')
plt.show()
```

```
C:\Users\aaloise\AppData\Local\Temp\ipykernel_8608\2075098783.py:2: FutureWarning:
```

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(x='TARGET_CUSTO_CATASTROFICO', y='IDADE', data=df_sample, palette='Set1')
```




Justificativa Visual: Selecionamos um gráfico de `boxplot` cruzando a Idade (contínua) com a variável alvo (categórica). O resultado indica claramente que internações classificadas como Custo Catastrófico possuem uma mediana de idade maior, evidenciando o risco financeiro concentrado em faixas etárias avançadas.

6. Matriz de Correlação

Avaliação de multicolinearidade linear entre os vetores de recursos numéricos disponíveis.

```
In [7]: plt.figure(figsize=(5, 4))
matriz_corr = df_sample[['IDADE', 'TARGET_CUSTO_CATASTROFICO']].corr()
sns.heatmap(matriz_corr, annot=True, cmap='coolwarm', vmin=-1, vmax=1)
plt.title('Matriz de Correlação Linear Base')
plt.tight_layout()
plt.savefig('matriz_correlacao.png')
plt.show()
```



Análise de Multicolinearidade: Nenhuma correlação linear perigosa ($|r| \geq 0.7$) foi detectada nas variáveis brutas iniciais, descartando problemas estruturais de colinearidade clássica.

7. Identificação de Problemas Estruturais

Auditoria profunda de integridade sobre as colunas da base nacional.

```
In [8]: print('Valores Nulos por Coluna:\n', df.isnull().sum())
print('\nTotal de Linhas Duplicadas no Dataset:', df.duplicated().sum())
q1 = df_sample['IDADE'].quantile(0.25)
q3 = df_sample['IDADE'].quantile(0.75)
iqr = q3 - q1
limite_superior = q3 + 1.5 * iqr
print(f'Limite Técnico Superior para Outliers (Idade): {limite_superior} anos')
```

Valores Nulos por Coluna:

MUNIC_RES	0
SEXO	0
VAL_TOT	0
DIAG_PRINC	0
GESTAO	0
MUNIC_MOV	0
IDADE	0
CAR_INT	0
INSTRU	0
TARGET_CUSTO_CATASTROFICO	0

dtype: int64

Total de Linhas Duplicadas no Dataset: 34374

Limite Técnico Superior para Outliers (Idade): 122.5 anos

8. Decisões de Limpeza e Justificativas

- **Valores Ausentes:** Serão tratados dinamicamente no pipeline usando `SimpleImputer` (mediana para numéricas, valor mais frequente para categóricas) para impedir vazamento de dados.
- **Duplicatas:** Perfis idênticos de faturamento serão mantidos, pois no faturamento do SUS é comum múltiplos pacientes compartilharem o mesmo perfil dentro do mesmo mês.
- **Outliers de Idade:** Pacientes acima do limite estatístico do IQR representam idosos de idade avançada reais no ambiente clínico, sendo preservados integralmente para não cegar o modelo.

9. Insights Estratégicos para a Modelagem

1. **Engenharia do CID:** Reduziremos a cardinalidade extraíndo o primeiro caractere (Capítulo do CID) para acelerar e dar inteligência ao codificador estrutural.
2. **Pesos de Classes:** O desbalanceamento (90/10) será mitigado ativando o parâmetro `class_weight='balanced'` nas árvores para eliminar viés na classe majoritária.
3. **Modularidade:** Toda a normalização numérica e codificação categórica será acoplada diretamente via `ColumnTransformer` dentro de um `Pipeline` rígido do scikit-learn.